

NSosyal Duygu Katmanı

Teknik özet (güncellenmiş sürüm) — TEKNOFEST NSosyal İnovasyon Yarışması (Sosyal Yapay Zekâ teması) · 19 Ağustos 2026

1. Ne yapıyoruz ve neden

NSosyal (T3 Vakfı + Baykar yapımı, ~700 bin+ kullanıcı, reklamsız mikroblog platformu) için duygu-duyarlı, açıklanabilir ve koruyucu bir sıralama/şeffaflık katmanı geliştiriyoruz. Sorun: sosyal medya akışları genelde "en yüksek etkileşim" için optimize edilir ve bu, duygusal olarak yoğun/olumsuz içeriği ödüllendirme eğilimindedir (Facebook'un kendi iç araştırmasında "öfke = en yüksek etkileşim" bulgusu gibi). Biz bunun yerine: kullanıcının ilgi alanından HİÇ SAPMADAN, sadece o an olumsuz bir davranışsal örüntüye ("spiral") girip girmediğini fark eden ve buna göre içeriğin dozunu nazikçe ayarlayan bir sistem kurduk. İçerik elenmiyor, sadece yumuşatılıyor -- ve her karar açıklanabilir olmak zorunda (kara kutu bir sinir ağı değil, denetlenebilir modeller). Bu, projenin şeffaflık tezinin temeli.

Neden bu kadar 'dürüstlük' vurgusu var?

Çünkü bu bir ruh sağlığı bağlamına yakın bir araç ve yanlış/abartılı bir iddia hem etik hem de itibar açısından riskli. Bu yüzden proje boyunca tekrarlanan bir disiplin var: vendor iddialarını sorgulamadan kabul etmemek, kendi ölçtüğümüz her sayıyı (iyi ya da kötü) olduğu gibi raporlamak, ve bir şey bozulduğunda/beklenenden kötü çıktığında saklamak yerine kök nedenini bulup düzeltmek. Bu belgede birkaç yerde "beklenenden kötü çıktı, sebebi X, düzeltme Y" şeklinde bölümler göreceksin -- bunlar kusur değil, metodolojik dürüstlüğü kanıtı olarak bilinçli şekilde saklandı.

Mimari — verinin izlediği yol (uçtan uca)

- 1. Gönderi metni → BERT modeli duygu skoru üretir (-1 ile +1 arası)
- 2. Kullanıcı etkileşimi → tarayıcıda Intersection Observer dwell-time'ı ölçer, tıklama/roket/yorum backend'e bildirilir
- 3. İKİ AYRI, birbirinden habersiz model bu sinyalleri yorumlar: (a) spiral tespiti (ikili, sıralamayı etkiler) ve (b) psikolojik durum tahmini (5 kategori, SADECE görüntüleme amaçlı — bkz. §6, bu ayırım kritik)
- 4. İki katmanlı sıralama motoru (motor.py) → ilgi skoru + refah katmanı (spiral seviyesine göre negatif içerik elenmez, sadece yumuşatılır)
- 5. Şeffaflık paneli → her karar ("neden bunu görüyorsun") kullanıcıya açık biçimde gösterilir
- 6. Haftalık/isteğe bağlı rapor → oturum verisi bir LLM'e (Gemini) özetletilip okunabilir bir metne çevrilir (bkz. §7)

2. Parametreler — Neden Bu Değerler, Neye Etki Ediyorlar

Sistemde ayarlanabilir her sabit rastgele seçilmedi; hepsinin somut bir gerekçesi var. Aşağıdaki tablo hepsini tek yerde topluyor (her biri kendi bölümünde de tekrar geçiyor):

Parametre	Değer	Neden	Neye etki eder
-----------	-------	-------	----------------

TAM_GUVEN_ESI GI	8	Az örneklemlili oran istatistiksel güvenilmez (kolayca %0/%100'e savrulur)	"Tespit edilen durum" göstergesinin ilk birkaç etkileşimde ne kadar bastırılacağı
DOGRULAMA_ARA LIGI	8	Çok sık sorulursa rahatsız eder, çok seyrek sorulursa veri birikmez (EMA literatürüyle uyumlu)	Kaç etkileşimde bir onay kartı çıkacağı
KISISEL_ETA0	0.12	Gerçekte çok daha küçük olurdu (~0.0005); demo'da TEK oturumda görünür olsun diye büyütüldü	Kişiselleştirilmiş modelin her onaydan sonra ne kadar kayacağı
saturate() tavanı	%75 (eskiden %45)	%45, seviye=1'de bile gözle zor fark ediliyordu — canlı testte yakalandı	Doygunluk azaltmanın maksimum görsel gücü
saturate() eğrisi	seviye^0.7	Doğrusal eğri orta seviyelerde neredeyse görünmezdi	Efekt ne kadar erken/belirgin fark edilir
refah_cezasi çarpanı	0.8	Tam çarpan (1.0) içeriği aşırı bastırabilirdi; 0.8 belirgin ama tam eleme değil	Sıralamada negatif içeriğin ne kadar aşağı düşeceği
_katki_agirligi aralığı	0.15 – 1.0	Hızlı kaydırma barları tek başına domine etmesin (tavan), kısa bakış da sıfır sayılmasın (taban)	Bir etkileşimin oturum ortalamasına katkı ağırlığı
StandardScaler	sabit/dondurul muş	dwel_saniye (0-15+) ile duygu (-1..1) ölçek farkı lineer modeli çarpıtiyordu	Hangi sinyalin tahminde ne kadar ağırlık taşıyacağı (F1: 0.686→0.704)
Gemini max_output_tokens	2048 (eskiden 600)	600'de model 'thinking' token'larını da aynı bütçeden harcayıp metni yarıda kesiyordu	Rapor metninin tam üretilip üretilemeyeceği

3. Duygu Analizi Modeli (BERT)

Temel model: savasy/bert-base-turkish-sentiment-cased (hazır Türkçe BERT, ikili pozitif/negatif sınıflandırma, nötr sınıfı yok).

Bağımsız doğrulama — vendor iddiasına güvenmedik, kendimiz ölçtük

winvoker/turkish-sentiment-analysis-dataset'ten rastgele 1000 örnek ile bağımsız test yapıldı (veri sızıntısı olmasın diye fine-tuning ve doğrulama TAMAMEN ayrık split'lerden geldi):

	Doğruluk	F1	Negatif precision
Vendor iddiası	%95.4	—	—
Bağımsız ölçüm (fine-tuning ÖNCESİ)	%69.8	0.778	0.372
Bağımsız ölçüm (fine-tuning SONRASI)	%94.3	0.964	0.803

Fine-tuning yöntemi (ince_ayar.py): aynı modelin, winvoker'ın split="test" bölümünden (doğrulama setinden tamamen ayrık) dengeli ~15.000 örnekle 2 epoch devam eğitimi. CPU'da (GPU yok) 2 saat 6 dakika sürdü.

Ek bulgu: modelin NSosyal-tarzı kısa/resmi haber-bülteni cümlelerinde (20 örnek elle test) orijinal ve ince-ayarlı model EŞİT çıktı (%65=%65) — fine-tuning bu alt-türde ne kazandırdı ne kaybettirdi, genel Türkçe metinde büyük kazanç sağladı. İnce ayarlı model üretimde kullanılıyor.

4. Spiral Tespiti (Lojistik Regresyon) — SIRALAMAYI ETKİLEYEN model

Kullanıcının son 20 farklı gönderiyle etkileşiminden 6 özellik çıkarılıp (motor.py), senaryo-bazlı sentetik veriyle eğitilmiş bir lojistik regresyon modeline verilir (spiral_model.py). Doğruluk: 0.714, F1: 0.748. Bu modelin çıktısı (spiral_seviyesi) hem sıralamayı hem renk uygunluğunu etkileyen TEK sinyal (bkz. §6).

Öğrenilen katsayılar (gerçek, açıklanabilir)

Özellik	Katsayı	Yorum
negatif_dwell_orani	+1.467	En güçlü etki: negatif içerikte geçirilen sürenin oranı
ortalama_duygu	-1.355	İçeriklerin genel tonu ne kadar negatifse durum o kadar artar
negatif_tekrar_sayisi	+0.421	(*) bkz. not aşağıda
tıklama_orani	-0.479	Tıklamadan sadece kaydırmak (pasif tüketim) durumu artırır
negatif_dwell_toplam	+0.061	Zayıf etki: mutlak saniye
kaydırma_hizi	+0.033	Çok zayıf etki: hızlı kaydırma (doomscroll göstergesi)
sabit (intercept)	-2.339	—

(*) negatif_tekrar_sayisi: roket/yorum spam'ini önlemek için backend artık gönderi başına tek kayıt tuttuğundan bu özellik canlıda her zaman 0 dönüyor — bilinen bir sınırlılık, kodda yorum olarak belgelendi.

Küçük örneklem güven düzeltmesi (TAM_GUVEN_ESIGI)

Az sayıda farklı gönderiyle (2-3 gibi) hesaplanan bir ORAN istatistiksel olarak güvenilirmez — kolayca %0 ya da %100'e savrulur. Yeterli veri (8 farklı gönderi) birikene kadar gösterilen değer kademeli olarak yumuşatılıyor ($guven_carpani = \min(1, gonderi_sayisi/8)$).

Sıralamaya etkisi (motor.py, sirala()): $refah_cezasi = spiral_seviyesi \times \max(0, -duygu) \times 0.8$; $final_skor = ilgi_skoru - refah_cezasi$. Yani spiral seviyesi yükseldikçe, negatif duygulu gönderiler puan kaybedip sıradaki sayfada aşağı düşüyor (elenmiyor, "yumuşatıldı" rozetiyle işaretleniyor).

5. Psikolojik Durum Sınıflandırıcısı (5 Kategori)

Tek bir "spiral var/yok" yerine, her etkileşim için 5 sinyalden (duygu, dwell-time, tıklama, roket, yorum) 5 kategoriden birine olasılık dağılımı üretiliyor: sakin, mutluluk, umut, sinirli, anksiyete. Model: SGDClassifier (log_loss), StandardScaler ile — F1 makro $\approx$ 0.70.

'Korku' neden 'sinirli' oldu (19.08.2026)

Orijinal tasarımda kategori "korku"ydu: negatif duygu + uzun donup-izleme + hiç etkileşim yok. Ama modülün kendi dosya-başı dürüstlük notu zaten şunu itiraf ediyordu: "korku ile anksiyete'yi ayırt etmenin bilimsel bir üst sınırı var" — çünkü ikisi de davranışsal olarak neredeyse AYNI imzayı taşıyordu ("negatif + pasif"). "Sinirli" (negatif duygu + roket/yorum VAR, aktif tepkisel katılım) davranışsal olarak GERÇEKTEN ayırt edilebilir bir örüntü — "korku"nun donup-pasif-izlemesinin tam tersi.

Sentetik senaryo tasarımı (güncel)

Kategori	Tasarım mantığı
sakin	Nötre yakın duygu, kısa dwell, neredeyse hiç etkileşim yok
mutluluk	Pozitif duygu + aktif katılım (roket/yorum sık)
umut	Pozitif duygu + uzun sessiz takip, roket/yorum nadir
sinirli	Negatif duygu + roket/yorum VAR (aktif, tepkisel katılım), kısa-orta dwell
anksiyete	Negatif duygu + kısa-tekrarlı dwell, huzursuz düşük etkileşim

Yan bulgu: kategori değişince F1 düştü, kök nedeni bulup düzelttik

Kategori değişip model yeniden eğitilince F1 makro 0.78'den 0.686'ya düştü. Kök neden araştırıldı: dwell_saniye (0-15+ saniye) ile duygu (-1..1) ve roket/yorum/tıklama (0/1) arasında BÜYÜK ölçek farkı var; lineer modelde ölçeklenmemiş büyük-skala özellik küçük olanları gölgeliyor. Eskiden bu gizliydi çünkü "korku"nun ayrımı neredeyse tamamen dev dwell büyüklüğüyle yapılıyordu; "sinirli" küçük skala olan duygu işaretine dayandığı için sorun görünür oldu. StandardScaler eklendi (eğitim + tahmin + kişiselleştirme güncellemesi — üçü de aynı dondurulmuş ölçekleyiciyi kullanıyor). Sonuç: F1 makro 0.704'e çıktı, kategoriler arası denge de düzeldi ("umut" precision 0.55→0.72).

Kategori	Precision	Recall	F1
anksiyete	0.57	0.73	0.64
mutluluk	0.81	0.70	0.75
sakin	0.68	0.79	0.73
sinirli	0.84	0.55	0.67
umut	0.72	0.76	0.74

0.70, eski 0.78'in altında ama bu dürüst, gerçek bir sayı — daha zor (ve daha savunulabilir) bir ayırım görevinin sonucu, uydurulmadı.

Neden hazır bir 'duygu kategorisi' modeli kullanılmadı

Araştırılan alternatifler (örn. maymuni/bert-base-turkish-cased-emotion-analysis) belgesiz eğitim verisi ve doğrulanmamış "%99.5 doğruluk" gibi şüpheli iddialar taşıyordu. Kendi açıklanabilir modelimiz tercih

edildi.

Arayüz düzeltmeleri (kullanıcı testi sırasında bulunan hatalar)

- Sinyal birleştirme: aynı gönderiye roket atıp sonra kaydırıp uzaklaşmak, önceden roket sinyalini sessizce eziyordu. Artık en uzun süre + tüm eylemlerin OR'u birleştiriliyor.
- Ağırlıklı ortalama: kısa/edilgen bir görünme (0.4sn) artık tam bir gözlem gibi sayılmıyor (ağırlık = dwell/4, roket/yorum/tıklama varsa = 1.0).
- Oturum boyunca kademeli birikme: tek bir olay artık barları %90+'a savurmuyor, tüm oturumun ağırlıklı ortalaması alınıyor.

6. Duygu/Spiral Barları — Hangisi Neyi Etkiliyor?

Bu ayırım kritik ve kolayca karıştırılabilir, o yüzden ayrı bir bölüm hak ediyor: sayfada İKİ AYRI gösterge var, ve sadece BİRİ sıradaki gönderileri etkiliyor.

A) 'Tespit edilen durum' göstergesi (üstteki tekil bar) → SIRALAMAYI ETKİLER

Bu, spiral_model.py'nin ikili çıktısı (spiral_seviyesi). motor.py'deki sirala() fonksiyonuna doğrudan parametre olarak giriyor ve refah_cezası'nı belirliyor (bkz. §4) — yani bu seviye yükseldikçe negatif gönderiler sıradaki sayfada gerçekten aşağı düşüyor. Aynı zamanda renk doygunluğu azaltmayı da bu değer tetikliyor (bkz. §7) — tek bir sinyal, iki görsel etki, tutarlılık için.

B) 5 kategorili 'olası izlenim' barları (mutluluk/umut/sakin/sinirli/anksiyete) → SADECE GÖRÜNTÜLEME

Bu tamamen AYRI bir model (psikolojik_durum.py), ayrı bir günlük (PSIKOLOJIK_GUNLUK) kullanıyor ve çıktısı sadece arayüzde gösteriliyor — motor.py'deki sirala() fonksiyonuna HİÇ geçmiyor. "%40 anksiyete" görsen bile bu, sıradaki gönderileri değiştirmiyor; sadece kullanıcıya kendi örüntüsünü gösteren bir ayna.

Bu bilinçli bir tasarım kararı: sıralamaya giren TEK sinyal spiral seviyesi olsun ki sistem açıklanabilir kalsın ("refah_cezası X çünkü spiral seviyesi Y" — tek, izlenebilir neden). 5 kategorili katman saf öz-farkındalık amaçlı; sıralamaya karışır sa hem açıklanabilirlik karmaşıklaşır hem de "duygu kategorimize göre içerik seçiyoruz" gibi bilinçli olarak reddettiğimiz bir yaklaşıma kayma riski doğar (bkz. §9).

Ekranda kalma süresi (dwell) barları nasıl etkiliyor?

İki farklı şekilde: (1) Doğrudan özellik olarak — dwell_saniye, sınıflandırıcının kullandığı 5 sinyalden biri, hangi kategorinin tahmin edileceğini belirliyor. (2) Ağırlık olarak — eğer o gönderide açık bir eylem (roket/yorum/tıklama) varsa süre ne olursa olsun tam ağırlık (1.0); sadece pasif dwell varsa ağırlık dwell_saniye/4'e endekslenip 0.15-1.0 arasına sıkıştırılıyor. Bu, sırf hızlı kaydırmanın barları tek başına domine etmesini önlemek için eklendi.

7. Renk Doygunluğu Azaltma

Spiral seviyesi yükseldikçe akışın CSS saturate() filtresi kademeli azalıyor — kesin bir engel değil, fark ettirmeye yönelik nazik bir görsel sinyal. Kullanıcı isteğiyle bir açma/kapama tuşu da eklendi. Ayrı bir ağırlıklı formül icat etmek yerine zaten eğitilmiş tek bileşik sinyal (spiral_seviyesi) tekrar kullanıldı — tutarlılık için.

Bulunan hata: teknik olarak çalışıyordu ama gözle görülmüyordu

Kullanıcı canlı testte fark etmediğini bildirdi. Tarayıcıda doğrulandı: mekanizma TEKNİK olarak doğru çalışıyordu (filter doğru uygulanıyordu), ama etki gözle görülemeyecek kadar küçüktü — iki sebep: (1) güven-çarpanı ilk birkaç etkileşimde spiral seviyesini kasıtlı bastırıyor (örn. %9'da doygunluk sadece %96 — fark edilmez), (2) eski formülün tavanı seviye=1'de bile sadece %45 azalmaydı. Güven bastırmasını korumayı seçtik (istatistiksel gerekçesi hâlâ geçerli), ama görünürlük eğrisini güçlendirdik:

Spiral seviyesi	Eski formül	Yeni formül
0.09 (ilk birkaç etkileşim)	saturate(~96%) — fark edilmez	saturate(~89%) — hâlâ hafif ama daha belirgin

0.33 (orta)	saturate(~85%)	saturate(66%)
1.00 (maksimum)	saturate(55%)	saturate(25%)

Formül: $\text{doygunluk\%} = 100 - (\text{seviye}^{0.7}) \times 75$. Üstel<1 eğri orta seviyelerde de belirginlik sağlıyor, sadece seviye=1'e çok yaklaşınca değil.

8. Aktif Öğrenme / Kendi Kendini Doğrulama Döngüsü

Davranış→psikoloji eşlemesi sentetik senaryolara dayanıyor, gerçek insan verisine değil. Bunu "doğrulanmış" gibi sunmak yerine, kullanıcıya her ~8 etkileşimde bir hafif bir onay sorusu soruyoruz ("şu an gerçekte nasıl hissediyorsun?") ve cevabı modelin O ANKI tahminiyle karşılaştırıyoruz. Model tahmini, tarafsızlık olmasın diye kullanıcı cevap vermeden ÖNCE hiç gösterilmiyor. Eşleşme oranı şeffafça raporlanıyor.

Literatür notu: bu mekanizma, psikolojideki "Ecological Momentary Assessment (EMA)" / "micro-EMA" yönteminin bağımsız bir yeniden keşfi (JMIR 2024;26:e50275; PMC7991987). Az soru + sık sorma prensibi literatürle örtüşüyor.

9. Kişiselleştirme (Online Learning)

Doğrulama cevapları modeli GERÇEKTEN güncelleyebilir mi? Evet — SGDClassifier'ın partial_fit özelliği kullanılarak, her doğrulama cevabından sonra modelde TEK küçük bir SGD adımı atılıyor. Varsayılan model (_VARSAYILAN_MODEL) hiç değişmiyor; ayrı bir kopya (_KISISEL) zamanla kayabiliyor.

Demo sorunu ve çözümü: gerçek kişiselleştirmeyi (çok kullanıcı, uzun vade) tek bir oturumda gösteremeyiz. Arayüze bir anahtar eklendi: "Varsayılan / Kişiselleştirilmiş" — aynı oturumun geçmişini seçilen modelle anında yeniden skorlayıp iki hâli karşılaştırıyor.

- Test sonucu: tek bir onay neredeyse etkisiz kalıyor (~3 puanlık kayma)
- Birkaç tutarlı onaydan sonra model gerçekten yön değiştiriyor (kişiselleştirilmiş kopyada gözlemlenebilir bir kayma)
- Dürüstlük notu: adım büyüklüğü (KISISEL_ETA0=0.12) demo'da görünür olması için kasıtlı büyütüldü — gerçek üretimde (binlerce kullanıcı, aylarca veri) çok daha küçük olurdu (~0.0005). Bu bir "gerçek kişiselleştirme kalibrasyonu" iddiası değil, mekanizmanın kanıt-of-konseptidir.
- İstikrar riski: az veriyle düzenleme olmadan online güncelleme modeli yanlış yöne kaydırabilir. Şu anki koruma: küçük adım + değişmeyen varsayılan model referans olarak kalıyor. Gerçek üründe düzenleme/sınır (clipping) eklenmeli.

10. Haftalık Rapor: Statik Örnekten Gerçek Zamanlı LLM'e

Rapor önce statik/sabit metinli bir örnek olarak gösterildi (formatı kanıtlamak için). 19.08.2026 gecesi gerçek LLM üretimine geçirildi: oturumda kaydedilen gerçek veri (kategori dağılımı, konu/saat örüntüleri, doğrulama eşleşme oranı) bir dil modeline özetletilip okunabilir bir rapor metnine çevriliyor.

Sağlayıcı seçimi: Claude değil, Gemini

İlk tasarım Anthropic/Claude API'siydi. Kullanıcının bütçe kısıtı sorması üzerine Google Gemini'ye geçildi (gemini-3.6-flash, google-genai kütüphanesi) — Gemini'nin kart istemeyen gerçek bir ücretsiz katmanı var, Claude API tamamen kullanım-bazlı ücretli. Mantık/prompt/sistem talimatı sağlayıcıdan bağımsız tasarlandı — tek bir fonksiyonu (uret()) değiştirmek başka bir sağlayıcıya geçmek için yeterli.

Canlı entegrasyonda çıkan iki gerçek sorun (saklanmadı, çözüldü)

- Model emekliye ayrılmış: gemini-2.5-flash artık yeni kullanıcılara kapalı; API'nin kendi hata mesajının önerdiği gemini-3.6-flash'a geçildi.
- Çıktı yarıda kesiliyordu: modelin "thinking" (iç muhakeme) token'ları da aynı max_output_tokens bütçesinden düşüyor. thinking_budget=0 ile tamamen kapatmak bu modelde reddedildi (400 hata) — çözüm thinking_level="low" + bütçeyi 2048'e çıkarmak oldu.

Gerçek üretimle doğrulanan örnek çıktı üç doğru bölümde geldi ("Gözlemlenen olası örüntü / İyi gidenler / Nazik bir not"), teşhis dili yok, temkinli ton korunuyor. API anahtarı yoksa (GEMINI_API_KEY tanımlı değilse) arayüz zaten var olan statik örneğe düşüyor — sahte bir LLM çıktısı asla uydurulmuyor.

Yeni: bir uzmana götürülebilecek veri özeti

Aynı LLM, kullanıcının isteğiyle, bir ruh sağlığı uzmanına götürebileceği YORUMSUZ bir ham veri özeti de hazırlayabiliyor. Kişisel rapordan (sıcak, "Nazik bir not" içeren) kasıtlı olarak FARKLI bir sistem talimatıyla çalışıyor: tavsiye/yorum/sonuç çıkarma YASAK, üçüncü şahıs+nötr dil, sadece "Veri Özeti / Gözlemlenen Davranışsal Örüntüler / Sınırlılıklar" başlıklarıyla ham sayıları sunuyor. "Sınırlılıklar" bölümünde modelin sentetik veriyle eğitildiğini, klinik doğrulaması olmadığını ve TEK BAŞINA hiçbir karar için yeterli olmadığını tekrar etmesi ZORUNLU kılındı. Otomatik yüklenmiyor — talep üzerine (bir buton ile) üretiliyor. Canlı test edildi; çıktı açılış cümlesinde "klinik bir belge değildir, nihai değerlendirme uzmana aittir" diyor ve hiç yorum/tavsiye içermiyor.

11. Diğer Teknik Düzeltmeler ve Araçlar

- Sayfalama (infinite scroll): 150 örnek gönderi (10 kategori × 15), gerçek sayfa sayfa (12'şer) yükleme, skor motoruna göre sıralı, tekrarsız
- Doğal çeşitlilik: final_skor'a küçük rastgele gürültü — her oturum sıfırlamasında birebir aynı sıra gelmiyor
- Roket/yorum spam koruması: aynı gönderiye art arda etkileşim artık günlüğü domine etmiyor, tek kayıta birleştiriliyor
- Tarayıcı önbellek yönetimi: statik dosyalar (?v=N) sürüm numarasıyla işaretleniyor, değişiklik yapıldığında bilinen bir tarayıcı önbellek hatasını önlemek için artırılıyor

12. Literatür Desteği (Gerçek Kaynaklarla)

Konu	Bulgu	Kaynak
EMA / micro-EMA	Doğrulama döngümüzün bağımsız bir uygulaması	JMIR 2024;26:e50275
Pasif kullanım / doomscrolling	Kaygı ilişkisi literatürde ORTA güçte (abartılmamalı)	JCMC 29(1), 2024 (141 çalışma meta-analizi)
Digital phenotyping	Davranıştan duygu çıkarımı meşru ama kişiye-özü kalibrasyon gerekli	JMIR 2025 scoping review
Refah-farkında sıralama	İki-katmanlı motorumuzun akademik emsali (CWB-RS)	arXiv:2102.04211
Açıklanabilirlik	"Az ama net" ilkesi — aşırı detay güveni azaltabilir	Springer World Wide Web journal

13. Önlemeye Çalıştığımız Şeyler / Olası Korkularımız

Bu projede teknik hatalardan çok, ETİK/İTİBAR riskleri konusunda temkinli davrandık. Bilinçli olarak reddedilen yaklaşımlar:

- Cohort-bazlı öneri ("kaygılı hissedenenlerin izlediğini göster") — Facebook'un "öfke=en yüksek etkileşim" tuzağına düşürme riski; anksiyeteli kullanıcılara "diğer anksiyeteli kullanıcıların izlediğini" göstermek doomscroll döngüsünü pekiştirebilir.
- Reklamı duygu durumuna göre hedeflemek — 2017'de sızan bir Facebook belgesi "worthless/insecure" hissedenen gençleri reklam hedeflemesi için kullanmayı önermişti. Biz TAM TERSİNİ yapıyoruz: kırılğan durumda reklamı bastırıyoruz, hedeflemiyoruz.
- İçerik kategorisine (siyasi/dini vb.) göre filtreleme — sistem KONU-NÖTR, sadece duygusal yoğunluğa bakıyor. Bu hem etik açıdan hem de bu platform (yerli/milli konumlandırılmış) için stratejik olarak riskli olurdu.
- Teşhis aracı gibi konuşmak — her metinde (kişisel rapor, terapist özeti, arayüz metinleri) "tespit ettik" değil "gözlemledik", "kesin" değil "olası" dili zorunlu kılındı; "tanı/hasta/bozukluk" kelimeleri hiçbir LLM promptunda kullanılmıyor.
- Sahte/abartılı teknik iddia — vendor'ın %95.4 doğruluk iddiasını sorgulamadan kabul etmek yerine bağımsız ölçtük (%69.8 çıktı), F1 düşüşünü (0.78→0.686) gizlemek yerine kök nedenini bulup düzelttik ve dürüstçe raporladık. Bu belgenin kendisi de bu disiplinin bir ürünü.
- Gerçek olmayan entegrasyon iddiası — NSosyal veya T3 AI'a gerçek bir API erişimimiz YOK. Bunu raporda "önerilen entegrasyon konsepti" olarak açıkça belirtiyoruz, gerçek bir entegrasyon varmış gibi sunmuyoruz.

14. Dürüstçe Belirtilmesi Gereken Sınırlılıklar

- BERT modeli hâlâ ikili (nötr sınıfı yok) — nötr metin zorla bir tarafa yuvarlanıyor
- Davranış→psikoloji eşlemesi sentetik senaryolara dayanıyor, klinik bir ölçüm değil
- "Sinirli" ile "anksiyete" ikisi de negatif duygu içerir ve gerçek dünyada iç içe geçebilir; F1≈0.70 bunun dürüst bir yansıması
- Kişiselleştirme mekanizması bir kanıt-of-konsept; gerçek üretimde düzenlileştirme/sınır eklenmeli
- Terapistle götürülebilir özet de dahil, hiçbir çıktı bir teşhis veya klinik değerlendirme aracı DEĞİL — yalnızca olası davranışsal örüntüleri gösterir, nihai değerlendirme her zaman uzmana aittir

Bu belge, TEKNOFEST NSosyal İnovasyon Yarışması (Sosyal Yapay Zekâ teması) için geliştirilen kanıt-of-konseptin teknik özetidir. NSosyal veya T3 AI'a gerçek bir API erişimi yoktur; tüm bileşenler bağımsız çalışır ve "önerilen entegrasyon konsepti" olarak sunulmaktadır.